



Вводная информация

Ларионова Ульяна
Преподаватель
ularionova@mail.tsu.ru

Ладно, давайте начинать, меня зовут ульяна, и вот с чего начнем. Очень часто Большинство курсов врут вам. Не намеренно — но врут.

Они дают вам чистые данные, пошаговые инструкции и правильные ответы в конце учебника. Выполнив все задания вы остаетесь с ощущением, что вы что-то умеете. А потом попадаете на реальный проект — и всё разваливается.

Потому что в реальности инструкцию, что делать, вам никто не написал.

Именно поэтому существует этот курс.

Про курс

Главная цель: понять, как устроена работа над ML-проектом в реальных условиях.

Организация работы



Формат: Проектная деятельность.

Команды: Группы по 3–4 человека.

Проект: Titanic. Предсказать, кто выжил

Структура и расписание:

- установочная лекция (сегодня).
- Практики (по средам): командная работа над проектом.
- Итоговая сдача проекта



Не будет лекций и лабораторных с инструкциями.

Следующие пять недель вы будете работать с задачей Титаника — одной из самых известных в машинном обучении. Задача простая: предсказать, кто выжил. Но именно в этой простоте и скрыта основная сложность.

Готовых инструкций не будет. Никто не скажет, какую модель взять, какие признаки создать, где ошибка в вашем коде. У вас будет теория, она будет рассказана либо сегодня, либо описана в курсе. Однако, вы столкнетесь с этим сами — в команде, в реальном времени.

Вы будете изучать, разбираться, объяснять друг другу, спорить. Заходить в тупики. Переделывать то, что казалось готовым. Именно так и выглядит настоящая работа над ML-проектом.

Почему это важно?

Потому что навык — это не то, что вы знаете. Это то, что вы можете сделать, когда столкнетесь с проблемой.

Теорию вы освоите самостоятельно — и это тоже часть задания. Но я буду рядом,

когда вы зайдёте в тупик и не будете понимать, почему модель не работает. Мы разберёмся вместе. Для этого у нас будут практики каждую неделю. На них вы можете мне задавать вопросы, просить консультации. Цель меня как преподавателя - создать для вас оптимальные условия для получения опыта.

Система оценивания




Максимум за проект: 100 баллов
Порог для зачета: 60 баллов

Структура оценки:
Качество модели — максимум 50 баллов
За проект — максимум 50 баллов

Итоговая сдача:
Командная защита проекта.

Контроль прогресса:
Необходимо 2 показа прогресса до итоговой сдачи:
• 1-й показ — в первой половине курса
• 2-й показ — во второй половине курса

Штраф: за отсутствие показа прогресса –20 баллов к итоговой оценке.



Как будет выставляться оценка

Всего за проект можно получить 100 баллов
для получения зачета по дисциплине вам надо набрать 60 баллов

баллы складываются из двух частей - оценка вашего кода (макс 50) + качество вашей модели (макс 50)
как они конкретно будут оцениваться - разберем сегодня в конце лекции

помимо этого - вам надо 2 раза показать прогресс до итоговой сдачи.
Я вам скину таблицу, куда вам с командой надо будет вписаться, когда вы планируете показать прогресс. Вам надо показать один раз прогресс в первой половине курса + во второй половине курса.
То есть на практике вы подходите ко мне, показываете, что у вас получилось. Я ставлю вам отметку, что прогресс показан.

если вы не показали прогресс -20 баллов к итоговой оценке

посещаемость на оценку не влияет, однако, вам все равно придется прийти, чтобы показать прогресс.

Правила использования чужого кода

Можно пользоваться любыми источниками.



Условие 1: Предупредить заранее или явно указать источник в работе.

Условие 2: Продемонстрировать понимание заимствованного кода.

Санкции за нарушение

- злоупотребление (большая часть задания выполнена не вами)
 - выдача за свой код (копирование без указания)
- работа оценивается в 0 баллов.

Команда теряет право на сдачу этой работы.



Главное, что нужно понять про наш курс: он про результат и понимание, а не про формальное выполнения заданий

Про списывание (или "заимствование"): Если вы взяли чужой код (у другой команды, с GitHub, из статьи), есть два условия, чтобы это не считалось списыванием:

Вы обязаны предупредить об этом заранее или явно указать это в работе.

Вы должны продемонстрировать, что понимаете этот код. Я задам вопросы. Если вы скопировали сложную модель и не можете объяснить, как она работает, — это провал.

Санкции: Если будет замечено злоупотребление (скопировали и выдали за свое), работа получает 0 баллов — команда теряет право сдать эту работу в принципе. Будьте честны с нами и с собой.



Работа с LLM

Рекомендую:

- Объяснения
 - "Объясни, как работает линейная регрессия простыми словами."
 - "Напиши комментарии для кода: [код]. Что в нем происходит?"
- Отладка кода (Debugging)
 - "Почему не работает код? Ошибка: [текст ошибки] в коде: [код]".
- Справка по библиотекам
 - "Как вывести описание всех колонок pandas DataFrame?"

Не рекомендую:

- Написание полноценного кода:
 - "Напиши код для предобработки данных"
 - "Напиши код для обучения нейронной сети"




Вы имеете полное право пользоваться любыми инструментами, включая ChatGPT и аналоги для пояснения теории или кода. Настоятельно не рекомендую просить генерировать готовый код. Разобраться в таком коде - гораздо сложнее. Если вы все таки сгенерируете код, правила аналогичные использованию чужого кода



Основные понятия машинного обучения

Часть 1


Ларионова Ульяна
Преподаватель
ularionova@mail.tsu.ru



Сейчас мы с вами погрузимся в основные термины и теорию
Во второй половине мы обсудим, какое задание вам надо выполнить

Artificial Intelligence Искусственный интеллект

Система, способная принимать
решения на основе состояния мира



Для начала, разберемся, что такое ИИ



Это Система, способная так или иначе принимать решения на основе состояния
мира

Наприме

Artificial Intelligence Искусственный интеллект

Система, способная принимать решения на основе состояния мира

Deep Blue



Например, один из первых, ИИ - Deep Blue —это [шахматный суперкомпьютер](#)^{[1][2]}. 11 мая 1997 года он выиграл матч из 6 партий у тогдашнего чемпиона мира [Гарри Каспарова](#).

Если упрощенно, как он работал:

- Система анализировала положение шахмат на доске
- Оптимизированным перебором среди всех возможных ходов искала лучший
- Определяла, какие ходы последуют далее
- Решала, как все таки лучше пойти


Для этого работала *целая экосистема сложных алгоритмов для принятия оптимального решения*

В данном примере позиции фигур на шахматном поле – состояние мира,

Artificial Intelligence Искусственный интеллект

Система, способная принимать решения на основе состояния мира

Deep Blue



AI




а Deep Blue - Система,

Artificial Intelligence Искусственный интеллект

Система, способная принимать
решения на основе состояния мира

Deep Blue



AI




способная принимать решения

Artificial Intelligence Искусственный интеллект

Система, способная принимать
решения
на основе состояния мира

Machine learning Машинное обучение

Система, принимающая
решения на основе
накопленного опыта и
состояния мира



ML – подобласть ИИ - Система, принимающая решения на основе накопленного опыта и состояния мира

Machine learning Машинное обучение

Система, принимающая решения на основе накопленного опыта и состояния мира



Для того, чтобы понять, что это значит, обратимся к тому, как принимает решение человек.

Предположим, вы вышли на улицу, там хмурое небо, вскоре идет дождь.

На следующий день вы выходите на улицу – небо ясное. Дождя не было.

– это
ваш накопленный опыт.

Machine learning Машинное обучение

Система, принимающая решения на основе накопленного опыта и состояния мира



На следующий день вы видите хмурое небо и берете зонт
В данном примере - Хмурое небо – состояние мира,

Machine learning Машинное обучение


Система, принимающая решения на основе накопленного опыта и состояния мира




а вы система, которая приняла решение на основе накопленного опыта и состояния мира

Machine learning Машинное обучение


Система, принимающая решения на основе накопленного опыта и состояния мира



Накопленный опыт



Состояние мира



Принятое решение




Если на более реальных примера, вы смотрите Клипы, и вам почему-то попадаются невероятно интересные, что хочется листать их вечно. Подбирают вам эти клипы с помощью МО

Система имеет накопленный опыт – информацию о всех пользователях, какие клипы они смотрели, какие лайкали, а какие быстро пролистывали
Состояние мира в данном случае – это то, какие клипы понравились именно вам.

Система на основе опыта понимает, что нравилось пользователям, которые лайкали примерно то же самое, и принимает решение – что показать дальше вам

Machine learning Машинное обучение

Система, принимающая решения на основе накопленного опыта и состояния мира



Накопленный
опыт



Состояние
мира

Привет! Чего д..

Принятое
решение




Или задача перевода аудио записи в текст.

системы, занимающихся переводом из текст в аудио, принимают решения на основе большого набора пар аудио записи и их текстовой расшифровки - это накопленный опыт

ваше голосовое сообщение - состояние мира
а принятое решение - то, как его перевести в текст

Machine learning Машинное обучение

Система, принимающая решения на основе накопленного опыта и состояния мира



Накопленный
опыт



Состояние
мира

Длительность
горения

Принятое
решение



Или предположим некая компания, продающая свечи, хочет знать, сколько будет гореть свечка по ее составу.

Уже есть набор данных, содержащий n свечей с их составом и скоростью горения. это накопленный опыт

новая свечка, скорость горения, которой нам неизвестна - состояние мира, а сколько она будет гореть - принятое решение

Machine learning Машинное обучение

Медицинский центр хочет предсказывать вероятность развития диабета 2-го типа у пациента на основе его возраста, индекса массы тела, уровня глюкозы в крови, наследственности и образа жизни.

Накопленный
опыт

Состояние
мира

Принятое
решение



Machine learning Машинное обучение

Агентство недвижимости хочет оценить рыночную стоимость квартиры на основе её характеристик (площадь, этаж, район, год постройки, материал стен).

Накопленный
опыт

Состояние
мира

Принятое
решение



Традиционное программирование



Давайте поймем, почему МО появилось
Для этого сравним его с традиционным программированием

Обычно мы пишем код следующим путем:

1. Анализируем проблему, для которой нужен код
2. Строим план решения и кодируете его
3. Отправляете данные в программу.
4. Получите желаемый результат на основе жестко закодированной логики.


например

Традиционное программирование



например, сложение

Традиционное программирование




или если вернуться к примеру с DEEP blue

Этот подход работает очень хорошо до тех пор, пока в игру не вступает определенный тип проблем.

Примеры проблем

- > перевести текст с одного языка на другой
- > диагностировать болезнь по симптомам
- > сравнить, какой из двух документов в интернете лучше подходит под данный поисковый запрос
- > сказать, что изображено на картинке
- > оценить, по какой цене удастся продать квартиру



Бывают задачи, которые для людей особенного труда не составляют, но которые почему-то крайне трудно запрограммировать, например:

- перевести текст с одного языка на другой;
- диагностировать болезнь по симптомам;
- И другой бесчисленный список задач

Машинное обучение



Чтобы написать компьютерную программу, решающую проблемы, которые мы не можем описать, пришлось изменить подход


Теперь, мы не формируем аналитически правила нахождения ответа, а формируем правила основываясь на данных и ответе

Итак, обычно процесс машинного обучения выглядит следующим образом:
Сбор данных о проблеме и определение правильных ответов . То есть -
(накопление опыта)


Отправка данных и ответов в систему

Получить правила, решающие задачу с определенным уровнем точности.

Сравнение традиционного программирования и машинного обучения




Итак, мы перешли от написания логической структуры программы к тому, чтобы заставить компьютер написать программу за нас, потому что она слишком сложна для нас, чтобы описать и написать ее.



Если бы писали калькулятор

Основные термины машинного обучения



Теперь перейдем к основным терминам


- В примере с дождем правила выводили вы

Основные термины машинного обучения




Однако в машинном обучении правила определяет модель машинного обучения

Основные термины машинного обучения




Процесс определения правил называется обучением

Основные термины машинного обучения




А правила называют - истинной зависимостью
то есть зависимость между данными и ответом

Основные термины машинного обучения



Данные называют обучающей выборкой. Они обычно имеют табличный вид, где все колонки с данными называются признаками (features), а ответ – целевая переменная (target) или же X и y.

Основные термины машинного обучения




Каждая отдельная взятая строка называется Объектом или наблюдением
object, sample.

Смысловое значение терминов

1


Обучающая выборка (training dataset)



Давайте зафиксируем смысл терминов

Смысловое значение терминов


- 1 Обучающая выборка (training dataset)
- 2 Истинная зависимость



Давайте зафиксируем смысл терминов

Смысловое значение терминов


- 1 Обучающая выборка (training dataset)
- 2 Истинная зависимость
- 3 Модель машинного обучения



Давайте зафиксируем смысл терминов

Смысловое значение терминов

- 1 Обучающая выборка (training dataset)
- 2 Истинная зависимость
- 3 Модель машинного обучения
- 4 Обучение



Давайте зафиксируем смысл терминов


Смысловое значение терминов

- 1 Обучающая выборка (training dataset)**
накопленный опыт. Каждый объект в выборке представляет собой набор признаков (features) и соответствующее ему значение целевой переменной (target).
- 2 Истинная зависимость**
правила перевода признаков в целевую переменную
- 3 Модель машинного обучения**
алгоритм, выявляющий истинную зависимость на основе обучающей выборки
- 4 Обучение**
процесс выявления истинной зависимости моделью машинного обучения




Давайте зафиксируем смысл терминов

Пример



Обучающая выборка		
Признаки		Целевая переменная
Состояние поля	Предыдущий ход соперника	Следующий ход
Пешка G2, ладья C3 ...	ладья на C3	Конь на F6
Слон B4, пешка G6 ...	Король на D5	Пешка на C5
....	...	



Вернемся к примеру с шахматами. Предположим, мы решили сделать ИИ для игры в шахматы с помощью Машинного обучения

Для этого нам необходимо собрать и подготовить данные.

Берем огромное кол-во партий гроссмейстеров и формируем на них данные


Из каждой партии формируем следующие признаки, например, состояние поля (какие фигуры где стоят) и предыдущий ход соперника.

Целевая переменная – какой ход гроссмейстер сделал следующим.

Пример

Состояние поля	Предыдущий ход соперника	Следующий ход
Пешка G2, ладья C3 ...	ладья на C3	Конь на F6
Слон B4, пешка G6 ...	Король на D5	Пешка на C5
....	...	


Обучающая выборка



Модель
машинного
обучения




Истинная
зависимость



Далее обучаем нашу модель. Мы подаем обучающую выборку в модель машинного обучения для определения зависимостей.

Пример




После того, как модель обучена, мы можем подавать в нее новые данные и получать для них ответ с некоторой точностью. Этот процесс называется предсказание.

Вопрос

В чем основная разница между Deep Blue и ML моделью?

Deep Blue



Алгоритм, принимающий решение



Модель
машинного
обучения



Давайте сравним, в чем принципиальная разница на примере Deep Blue
Deep Blue принимает решение на основе алгоритма с правилами,
определенными человеком аналитическим путем

Модель машинного обучения принимает решение на основе правил,
выведенных из накопленного опыта, то есть данных.

Artificial Intelligence Искусственный интеллект


Система, способная принимать решения на основе состояния мира

Machine learning Машинное обучение

Система, принимающая решения на основе накопленного опыта и состояния мира

Deep learning Глубокое обучение

Подоблась машинного обучения, основанная на нейронных сетях



Еще одна подоблась МЛ -


ДЛ - это машинное обучение, где в качестве модели используются нейросети.

Когда нужно Машинное обучение?



Когда нужно Машинное обучение?

Определять правила для решения задачи самостоятельно сложно и долго



Когда нужно Машинное обучение?

Определять правила для решения задачи самостоятельно сложно и долго




Пример

Есть фотографии собак и кошек, необходимо определить, какое животное находится на фото



Пример

Есть масса тела и ускорение свободного падения. Необходимо рассчитать силу тяжести, действующую на предмет



Когда нужно Машинное обучение?

Нужно учесть множество факторов и условий



Когда нужно Машинное обучение?

Нужно учесть множество факторов и условий



Пример

Есть разнообразные параметры автомобиля. Необходимо определить стоимость




Когда можно Машинное обучение?

Есть данные.

Основываясь на данных модель выявляет истинную зависимость. Если данных мало или они плохого качества, то и истинная зависимость будет выявлена плохо.

В таком случае качество предсказаний будет низкое.







образовательный проект
ЦИФРОВЫЕ
КАФЕДРЫ

Виды машинного обучения

Ларионова Ульяна
Преподаватель
ularionova@mail.tsu.ru






На данном слайде представлена визуализация разных областей машинного обучения. пройдемся по самым распространенным из них

Обучение с учителем supervised learning

Правильные ответы для каждого объекта обучающей выборки заранее известны



Все приведенные ранее в этом курсе примеры являются обучением с учителем (supervised learning), так как правильные ответы для каждого объекта обучающей выборки заранее известны. Важно понять: под учителем подразумевается именно набор ответов. Никакого реального учителя с указкой нет.

Задачи обучения с учителем делятся на разные виды в зависимости от того, каким может быть множество всех возможных ответов Y

Регрессия

$$Y=R \text{ или } Y=R^k$$

- предсказание продолжительности поездки на каршеринге
- спрос на конкретный товар в конкретный день
- погода в вашем городе на завтра



Первый вид задач обучения с учителем - регрессия. в данном случае - ответ - любое действительное число, или набор действительных чисел

Примерами задач регрессии является предсказание продолжительности поездки на каршеринге, спрос на конкретный товар в конкретный день или погода в вашем городе на завтра

Многоклассовая классификация

$$Y=1,...,K$$

- определение предметной области для научной статьи
- классификация типов рака
- классификация дорожных знаков для систем автономного вождения



следующий вид - классификация
здесь ответом может быть ответ из заранее определенного набора.
Например, определение предметной области для научной статьи
(математика, биология, психология и т. д.).

Бинарная классификация

$Y=0, 1$

- кликнет ли пользователь по рекламному объявлению
- вернёт ли клиент кредит в установленный срок
- сдаст ли студент сессию



бинарная классификация, где набор ответов состоит из 0 и 1. мы можем предсказывать, кликнет ли пользователь по рекламному объявлению, случится ли определённое заболевание у пациента, есть ли на картинке банан.

multilabel classification

$$\mathbf{Y} = 0,1^K$$

- автоматическое проставления тегов для ресторанов
- проставление жанров музыки



многоклассовая классификация с пересекающимися классами (multilabel classification).

здесь ответ - несколько классов

Например, задача автоматического проставления тегов для ресторанов (логично, что ресторан может одновременно иметь несколько тегов).

К какой задаче относятся следующие примеры:

По признакам необходимо определить вид ириса (Iris setosa, Iris versicolor или Iris virginica).


Длина чашелистика	Ширина чашелистика	Длина лепестка	Ширина лепестка	Вид ириса
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
5.0	2.3	3.3	1.0	versicolor
5.6	2.7	4.2	1.3	versicolor
5.7	3.0	4.2	1.2	versicolor
5.7	2.9	4.2	1.3	versicolor
6.2	2.9	4.3	1.3	versicolor

Регрессия

Многоклассовая классификация

Бинарная классификация

Многоклассовая классификация с пересекающимися классами



К какой задаче относятся следующие примеры:

Имеются метеоданные за последние 5 лет: давление, влажность, скорость ветра, а также фактическая температура воздуха в полдень каждого дня.

Необходимо построить модель для предсказания числового значения температуры

Регрессия

Многоклассовая классификация


Бинарная классификация

Многоклассовая классификация с пересекающимися классами



Обучение без учителя unsupervised learning


Правильные ответы для каждого объекта обучающей выборки заранее НЕ известны



Есть класс задач, относящихся к обучению без учителя (unsupervised learning), — это задачи, для которых нам известны только данные, а ответы неизвестны или вообще не существуют. Более того, часто поиск "правильных" ответов не является самоцелью.

Кластеризация

- кластеризация документов из электронной библиотеки по темам
- кластеризация новостей по сюжетам
- ответов респондентов по содержанию



Классическим примером обучения без учителя является кластеризация — задача разделения объектов на группы, обладающие некоторыми неизвестными нам, но, как мы в глубине души надеемся, интерпретируемыми свойствами. Примером может служить кластеризация документов из электронной библиотеки по темам или кластеризация новостей с целью выделения крупных сюжетов.


Обучение с подкреплением Reinforcement learning

Алгоритм за каждое действие получает награду или наказание



еще класс задач. обучение с подкреплением. основан па том, что алгоритм за каждое свое действие получает награду или наказание.
Здесь предсказание модели - следующее действие. Желательно самое выгодное :)


AlphaGo сыграл сам с собой миллионы партий.




Однако, помимо рассмотренных задач, есть еще задачи, где ответ гораздо сложнее

Так, в задаче сегментации изображения требуется для каждого пикселя предсказать, к какому объекту или типу объектов он относится,


**Я люблю
машинное
обучение**



**I love machine
learning**



а в задаче машинного перевода мы должны сгенерировать предложение (или целый текст), являющееся переводом исходного.




Интерес представляют и задачи порождения новых объектов, то есть генерации правдоподобных объектов, из ничего или на основе уже существующих. С помощью такой модели также можно научиться увеличивать разрешение изображения и применять любимые всеми маски в соцсетях.



Проект

Ларионова Ульяна
Преподаватель
ularionova@mail.tsu.ru



Теперь я расскажу вам о вашем первом серьезном проектном задании —


Titanic: Machine Learning from Disaster

15 апреля 1912 года — столкновение с айсбергом в первом рейсе

2224 человека на борту, 1502 погибших

Выжило всего 32% пассажиров

Причина: нехватка шлюпок



соревновании по машинному обучению "Titanic: Machine Learning from Disaster"

В чем суть:

Крушение «Титаника», произошедшее 15 апреля 1912 года, — одна из самых известных морских катастроф в истории. Во время своего первого плавания лайнер столкнулся с айсбергом и затонул, унеся жизни 1502 человек из 2224 находившихся на борту. Эта трагедия потрясла мировое сообщество и привела к ужесточению правил безопасности на море.

Одной из ключевых причин столь высокой смертности стало катастрофическое отсутствие спасательных шлюпок. Однако анализ трагедии показывает, что выживание не было случайностью. Определенные группы пассажиров имели значительно более высокие шансы на спасение: женщины, дети и представители высшего класса.

Titanic: Machine Learning from Disaster

Что мы знаем о пассажирах?


Возраст, пол, класс билета, порт посадки и др.

Задача:

Предсказать: выжил пассажир (1) или погиб (0)

Цель проекта:

Пройти полный путь data scientist'a: от анализа данных до готовой модели прогнозирования выживания



Нам даны данные о пассажирах "Титаника": их возраст, пол, класс билета, порт посадки и так далее.

Задача: На основе этих данных обучить алгоритм, который предскажет для каждого пассажира из тестовой выборки: выжил он (1) или нет (0)».

Ваша цель — не просто написать код, а пройти полный путь инженера по данным: от исследования данных до создания модели, которая предскажет, кто выживет, а кто погибнет в этой известной катастрофе

Этапы работы над проектом

1. Определение проблемы (Problem Definition)
2. Сбор данных (Data Gathering)
3. Подготовка данных (Data Preparation / Wrangling)
4. Исследовательский анализ (Exploratory Analysis)
5. Инженерия признаков (Feature Engineering)
6. Обучение модели
7. Валидация и внедрение модели (Validation & Implementation)
8. Оптимизация и стратегирование (Optimization & Strategize)

Работа над любым проектом в области машинного обучения — это не просто написание кода. Это сложный и итеративный процесс, который требует системного подхода. Чтобы проект был успешным, необходимо пройти несколько ключевых этапов. Рассмотрим их последовательно.

1. Определение проблемы (Problem Definition)
2. Сбор данных (Data Gathering)
3. Подготовка данных (Data Preparation / Wrangling)): "Чистим" данные. Заполняем пропуски, превращаем текстовые данные (например, пол) в числа, создаем новые признаки (например, длину имени или размер семьи).
4. Исследовательский анализ (Exploratory Analysis): Знакомимся с данными. Ищем пропуски, рисуем графики, смотрим, какие признаки влияют на выживаемость.
5. инженерия признаков
6. обучение модели: Выбираем алгоритм (Логистическая регрессия, Random Forest, или даже нейросеть), обучаем на тренировочных данных.
7. Валидация и внедрение модели (Validation & Implementation)
8. Оптимизация и стратегия (Optimization & Strategize)

Работа с моделями состоит последовательно из этих этапов, однако бывают случаи, когда возможны исключения: мы можем комбинировать несколько этапов рабочего процесса; можем анализировать данные до и после обработки;

выполнять этап несколько раз, например, этап EDA


Kaggle

Kaggle - это международная платформа, на которой проводятся соревнования по анализу данных.

На платформе есть соревнования для новичков, они помечены тегами:


- getting started
- knowledge
- playground

Помимо этого, там опубликовано огромное количество датасетов под разные задачи.




соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.




соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.



соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.



соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.

Kaggle

Table of Contents

Project: Predicting Survival on the T...

Блок 0. Работа с kaggle

Описание датасета

Оценка модели

Блок 1. Исследование структуры ...


Блок 2. Разведочный анализ данн...

Задание 3. Разведочный анализ д.

Блок 3. Обработка данных

Задание 7. Нормализация признаков

Блок 4. Обучение модели



соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.

Kaggle

Table of Contents

Project: Predicting Survival on the T...

Блок 0. Работа с kaggle

Описание датасета

Оценка модели

Блок 1. Исследование структуры ...

Блок 2. Разведочный анализ данн...

Задание 3. Разведочный анализ д.

Блок 3. Обработка данных

Задание 7. Нормализация признаков

Блок 4. Обучение модели

Задание 4. Обработка пустых значений (10 баллов)

Выведите сколько пропусков в колонках. Изучите природу пропусков в колонках. Для каждой колонки определите способ избавления от пропусков и используйте его.

Вопросы для самопроверки:

- Какие колонки имеют пропуски?
- Сколько пропусков в каждой?
- Можно ли удалить колонку?
- Можно ли удалить строки с пропусками?
- Пропуск в категориальной колонке или в числовой?
- Как лучше заполнить пропуски?


соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.

Работа в команде

Договоритесь о целях:

- Получить топ по метрикам, закрыть задание на максимум
- Попробовать, поэкспериментировать
- Пройти планку сдачи курса




соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.

Работа в команде

- Выберите формат встреч и время:
- Встречаетесь очно или онлайн
- Разбираете теорию самостоятельно или вместе
- Пишете код самостоятельно, потом обсуждаете результат и прогресс, либо пишете код одновременно




соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.

Работа в команде

Работайте итеративно:

Сначала пройдите все этапы, потом возвращайтесь к
прошлым шагам и постепенно их улучшайте



соревновании по машинному обучению "Titanic: Machine Learning from Disaster" на платформе Kaggle.

Для тех, кто не знаком: Kaggle — это международная платформа для соревнований по Data Science. Вводная инструкция по работе с этой платформой уже опубликована на странице курса. "Титаник" — это стартовое соревнование, с которого начинают все специалисты в мире.



Спасибо за внимание

Ларионова Ульяна
Преподаватель
ularionova@mail.tsu.ru

